Yapay Nöron Ağları ve Destek Vektör Makineleri ile İkili Sınıflandırma

Tuğcan Topaloğlu
Fen Bilimleri Fakültesi Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
Ankara, Türkiye
topaloglutugcan@gmail.com

***Özet*—Bu çalışma, make_moons fonksiyonu kullanılarak oluşturulan sentetik bir veri kümesinde ikili sınıflandırma için Yapay Sinir Ağları (YSA) ve Destek Vektör Makineleri (DVM) performanslarını değerlendirmektedir. YSA için farklı gizli katman konfigürasyonları ve optimizasyon yöntemleri, DVM için ise farklı çekirdek türleri kullanılarak eğitim ve doğrulama yapılmıştır. Sonuçlar, YSA için Mini-Batch Gradient Descent ve DVM için Gaussian RBF çekirdeğinin yüksek doğruluk ve genelleme yeteneği sağladığını göstermiştir. Karar sınırları, karışıklık matrisleri ve doğruluk, kesinlik, geri çağırma ve F1 skoru gibi değerlendirme metrikleri analiz edilerek model performansına dair kapsamlı bilgiler sunulmuştur. Bu çalışma, ikili sınıflandırma görevleri için model seçimi ve optimizasyon konularına katkıda bulunmaktadır.**

Anahtar Kelimeler—İkili Sınıflandırma, Yapay Sinir Ağları, Destek Vektör Makineleri, Mini-Batch Gradient Descent, Gaussian RBF Çekirdek, Model Optimizasyonu

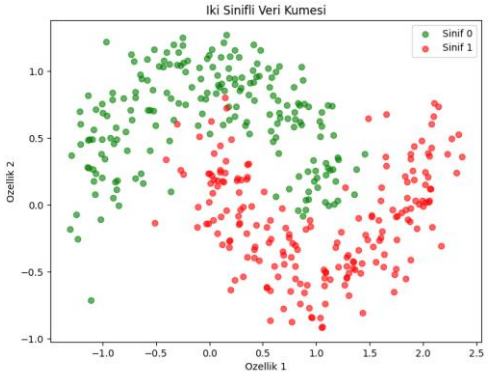
I. GIRIŞ

İkili sınıflandırma yöntemi birçok alanda kullanılmaktadır. Bu alanlar arasında spam tespiti, hastaya teşhis konulması gibi birçok alan bulunur. Bu çalışmada da bu gibi yöntemlerde uygulayabilmek amacıyla Yapay Sinir Ağları (ANN) ve Destek Vektör Makineleri (SVM) yöntemleri test edilmiştir. Yöntemlerin test edilmesi amacıyla çalışmada *scikit-learn* kütüphanesi yardımıyla *make_moons* fonksiyonu kullanılarak veri 400 verilik bir veri kümesi oluşturulmuştur. Amaç bu yöntemlerin doğrusal olmayan veri desenlerini yakalama ve sınıf örtüşmelerini anlayabilme yeteneklerini karşılaştırmaktır. Değerlendirme olarak *accuracy, recall, precision* ve *F1 Score* değerleri hesaplanmış ve en başarılı yöntem belirlenmiştir. Ayrıca işlemler yapılırken *overfitting* ve *underfitting* olup olmadığı da test edilmiştir.

II. DENEYSEL ANALIZ

A. Veri Setinin Hazırlanması

Çalışmanın yapılabilmesi amacıyla *scikit-learn* kütüphanesi implemente edilmiş ve ardından bu kütüphaneye ait *make_moons* metodu ile 400 örnekten oluşan iki sınıflı veri kümesi oluşturulmuştur. Oluşturulan veri kümesi %60 eğitim (train), %20 doğrulama (validation) ve %20 test verisi olarak bölünmüştür. Bu şekilde eğitim ve doğrulamayı kullanarak hem sonuçlarımızı daha doğru hala getireceğiz hem de test verisini ayırmış olduğumuzdan bu test verisi üzerinde gereken ilgili testler yapılıp başarı ölçümü yapılacaktır. Şekil 1, veri kümesindeki iki sınıfın dağılımını göstermektedir. Sınıf 0 ve Sınıf 1 sırasıyla yeşil ve kırmızı noktalarla temsil edilmiştir.



Şekil 1. Veri setinin örnek dağılım grafiği

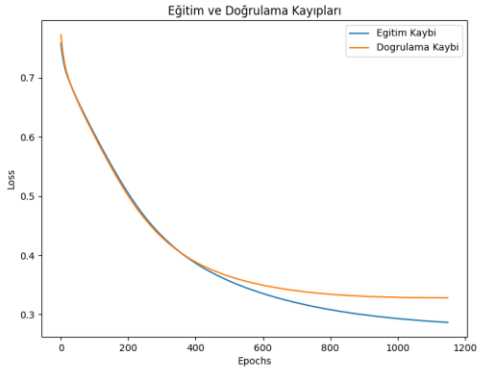
B. Yapay Nöron Ağı (ANN) Öğrenme Modelinin Uygulanması

ANN yapısı veri seti üzerinde çalıştırıldı. Bu yapı çalıştırılırken *loss* fonksiyonu olarak ödevde belirtildiği üzere *Binary Cross Entropy* yöntemi kullanıldı. Ayrıca aktivasyon fonksiyonu olarak daha önceki ödevde kullandığımız gibi *sigmoid* fonksiyonu kullanıldı. Ardından bu ANN yapısı farklı katmanlarda çalıştırılarak sonuçlar analiz edildi. İlk beklentim katman sayısı arttıkça başarının artması yönündeydi ancak elde ettiğim sonuçları ve grafikleri incelediğimizde daha farklı sonuçlar elde ettik ve bunun nedenini değerlendireceğiz.

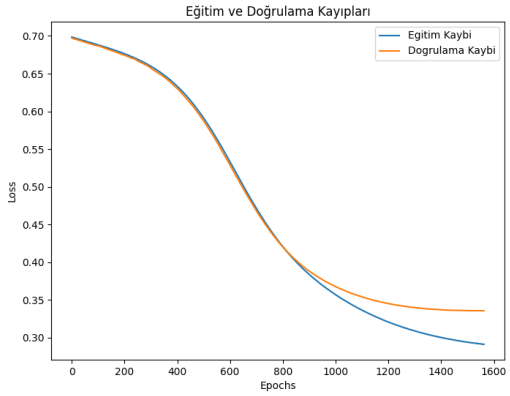
Sistemimizde aynı yöntemle eğitilecek ancak katman sayısı 1,2 ve 3 olarak değişecek şekilde bir kodlama yapısı kuruldu. Bu şekilde farklı katmanlar için değerlendirme yapabiliriz. Ayrıca burada gerçekleştirdiğimiz tüm ANN eğitimlerini ilk olarak 100 *epoch* ile çalıştırdım. Bunun sonucunda 100 *epoch* ile eğitimin tamamlanmadığını fark ettim. Bunun üzerine *epoch* sayısını 10000 *epoch* olarak belirleyip *early stopping* ve *overfitting-underfitting* optimizasyonu gerçekleştirdim. Bu şekilde aslında tüm 10000 *epoch*'u tamamen dönmeyecek ve eğitim bittiği anda duracak. Test edilmek istenirse kod üzerinde yorum satırları kaldırılarak 100 ve 1000 *epoch* için de testler yapılabilir. Ekstra bir işlem yapılması gerekmemektedir. Ayrıca tüm örneklerde öğrenme katsayısı 0.01 olarak belirlenmiştir. Tüm modeller eğitilip ardından test verisi üzerinde test edilmiştir.

1) Stochastic Gradient Descent (SGD)

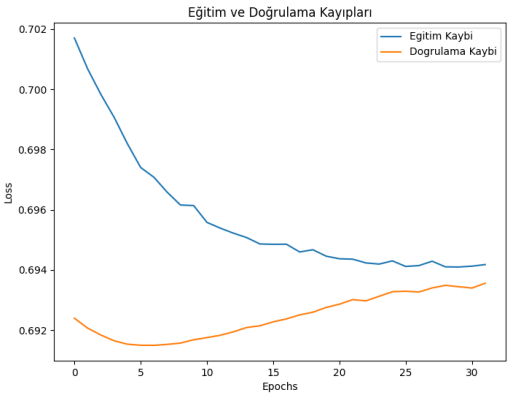
ANN yapısını ilk uygulayacağımız yöntem SGD yöntemi bu yöntemin genel olarak başarılı ve hızlı sonuç veren bir yöntem. Bu yöntemi daha önce belirttiğimiz yöntemlerle çalıştırdığımız *loss* fonksiyonu 1 katmanlı mimari için şekil 2, 2 katmanlı mimari için şekil 3 ve 3 katmanlı mimari için şekil 4'teki gibi gözlemlenmektedir.



Şekil 2. SGD 1 Katman Loss Grafiği ve Early Stopping Noktası

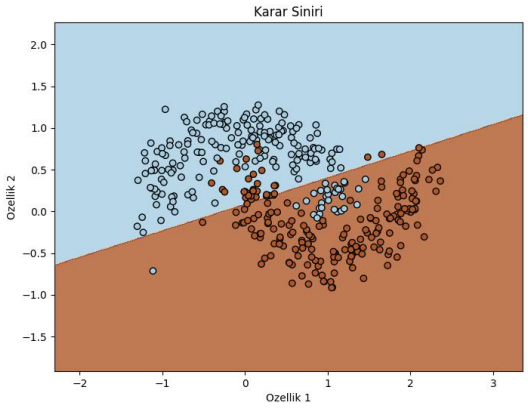


Şekil 3. SGD 2 Katman Loss Grafiği ve Early Stopping Noktası

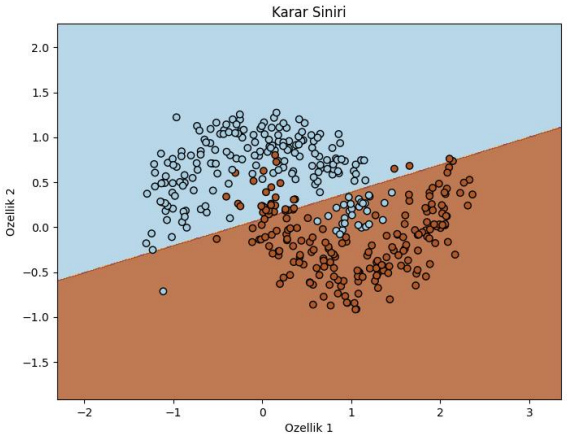


Şekil 4. SGD 3 Katman Loss Grafiği ve Early Stopping Noktası

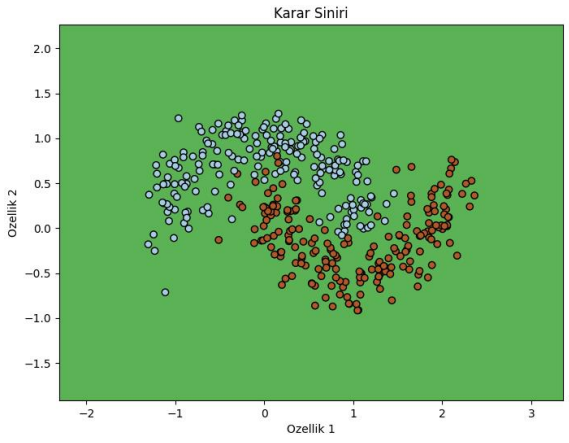
Loss grafiklerini incelediğimizde *epoch* ilerledikçe birinci ve ikinci grafikte doğrulama kayıplarının eğitim kayıplarından daha yüksek olmaya başladığını görüyoruz bu bize bir *overfitting* göstergesi olabilir. Bu yüzden de *early stopping* uyguladık ve bunun fayda saylayacağını bekliyoruz. Program çıktılarına baktığımızda da bu sonuçların aynı şekilde *overfitting*'e neden olabileceğini görüyoruz. Çalıştırmış olduğumuz 3 katman da tam *epoch* sayısını tamamlamadan *early stopping* ile durdurulmuş gözüküyor. Bu da eğitimin tamamlandığına işaret ediyor. Loss grafiklerini kontrol ettiğimizde bu değerlerin çok kötü başarılar vermeyeceğini tahmin edebiliyoruz. Ardından bu modellerin nasıl karar verdiğini daha iyi görebilmek adına *decision boundary*'lerini inceliyoruz. Şekil 5, 6 ve 7'de bu karar sınırlarını görebiliriz.



Şekil 5. SGD 1 Katman Karar Sınırı

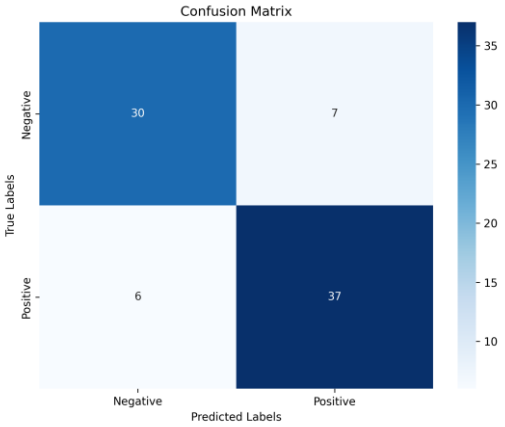


Şekil 6. SGD 2 Katman Karar Sınırı

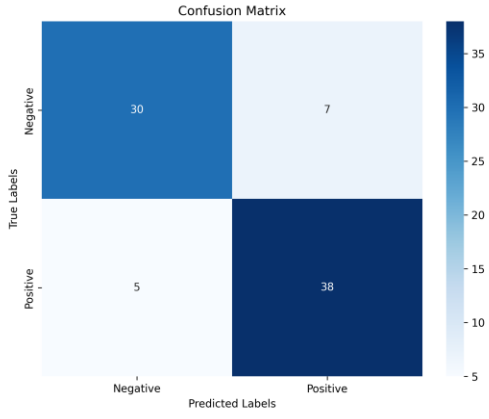


Şekil 7. SGD 3 Katman Karar Sınırı

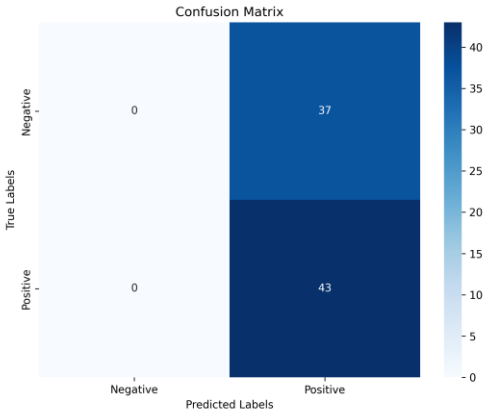
Karar sınırlarını inceledğimizde şunları görüyoruz. 1 ve 2 katmanlı ANN mimarisinde karar sınırları anlamlı ve birbirine çok yakın gözüküyor. Sınırlar *lineer* çizildiğinden dolayı bu veri setinde mükemmel sonuçlar vermeyecektir ancak bu modele uygun iyi sonuçlar verecektir. Sonuçları incelediğimizde bunları daha iyi gözlemleyeceğiz. 3 katmanlı mimariye geldiğimizde ise karar sınırının çizilemediğini görüyoruz. Bunun muhtemel nedeni 3 katmanlı mimari bu tarz bir veri kümesini çok fazla kompleks hale getirip modelin sınıflandırma yapamamasına ve tüm verilere aynı değeri demesine neden oluyor. Bundan dolayı az sınıflı ve verili modellerde *ANN* kullanacaksak katman sayısını çok fazla arttırıp problemi kompleks hale getirmememiz gerektiğini görüyoruz. Sonuçların anlamlandırılması için şekil 8, 9 ve 10'daki *confusion matrix*'leri incelediğimizde 1 katmanlı ve 2 katmanlı modelin yakın ve başarılı sonuçlar verdiğini ancak 3 katmanlı modelin iyi sonuç vermediğini görüyoruz.



Şekil 8. SGD 1 Katman Confusion Matrix



Şekil 9. SGD 2 Katman Confusion Matrix



Şekil 10. SGD 3 Katman Confusion Matrix

Bu matrix'lerin yanında metrikleri de inceleyelim. Her katman için tablo 1, 2 ve 3'teki metrikleri incelediğimizde SGD için en başarılı sonucun %83 ve %86 başarı ile 2 katmanlı SGD olduğunu tahminliyoruz ancak 1 katmanlı mimari de çok farklı bir sonuç vermiyor ikisinden birisi tercih edilebilir. Biz *F1 Score* değerini esas alarak 2 katmanlıyı daha iyi seçiyoruz. Bir sonraki başarılı sonuç ise 1 katmanlı mimariden çıkıyor. En başarısız modelin ise fazla değerlendirme sonucu olduğunu düşündüğümüz tablo 3'te bulunan 3 katmanlı mimari veriyor.

TABLO I. 1 KATMANLI SGD METRIKLERI

1 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.2865
Doğrulama Kaybı	0.3281
Accuracy	0.84
Precision (Class 0)	0.83
Precision (Class 1)	0.84
Recall (Class 0)	0.81
Recall (Class 1)	0.86
F1-Score (Class 0)	0.82
F1-Score (Class 1)	0.85

TABLO II. 2 KATMANLI SGD METRIKLERI

2 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.2914
Doğrulama Kaybı	0.3359
Accuracy	0.85
Precision (Class 0)	0.86
Precision (Class 1)	0.84
Recall (Class 0)	0.81
Recall (Class 1)	0.88
F1-Score (Class 0)	0.83

2 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
F1-Score (Class 1)	0.86

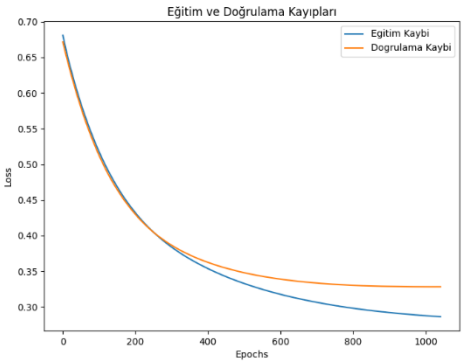
TABLO III. 3 KATMANLI SGD METRIKLERI

3 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.6942
Doğrulama Kaybı	0.6936
Accuracy	0.54
Precision (Class 0)	0.0
Precision (Class 1)	0.54
Recall (Class 0)	0.0
Recall (Class 1)	1.0
F1-Score (Class 0)	0.0
F1-Score (Class 1)	0.7

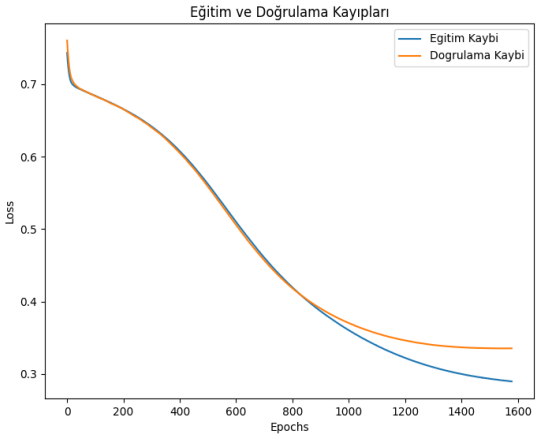
SGD için modelleri değerlendirdiğimizde sonuç olarak 1 ve 2 numaralı modelleri en başarılı bulduk. Ancak bunlardan *F1 Score*'u biraz daha yüksek olan 2 katmanlı olan model 2'nin daha başarılı olduğunu söyleyebiliriz. Bu sonuca göre bu modeller için en başarılı modelin *loss* grafiği şekil 2'de karar sınırı şekil 6'da *confusion matrix*'i şekil 9'da ve metrikleri tablo 2'de bulunabilir. Erken durdurma gibi bazı düzenlemelerle azaltılmış olsa da hem 2 katmanlı hem de 1 katmanlı modeller için bir miktar *overfitting*'in devam ettiğini tahmin ediyoruz.

2) Mini Batch Gradient Descent (MBGD)

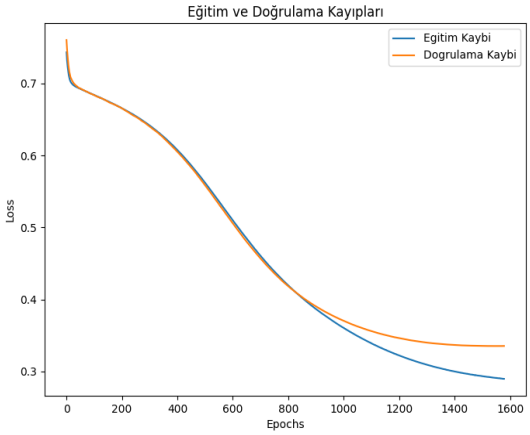
SGD modelinin ardından *MBGD* modeli için de aynı işlemleri uygulayacağız.



Şekil 11. MBGD 1 Katman Loss Grafiği

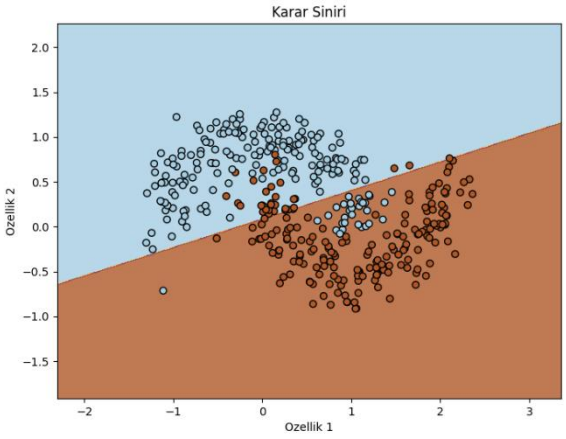


Şekil 12. MBGD 2 Katman Loss Grafiği

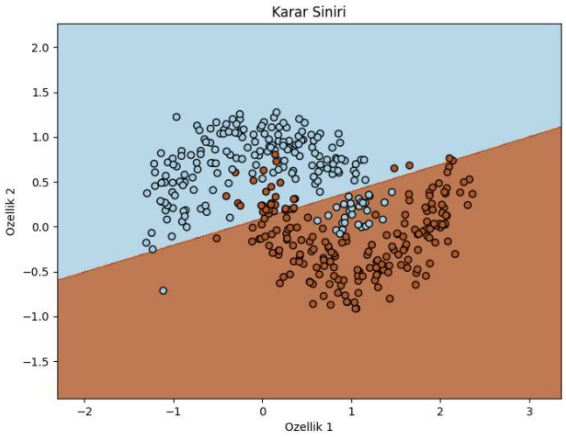


Şekil 13. MBGD 1 Katman Loss Grafiği

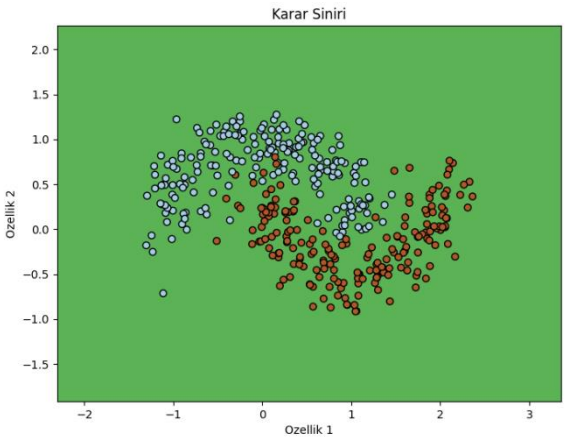
Şekil 11, 12 ve 13'de loss grafikleri görülebilir. Yine bu loss grafiklerinde gördüğümüz üzere bir miktar overfitting olabilir. *Loss* grafiklerinde de görülen *early stopping* yöntemi daha erken uygulanabilirdi (örneğin 2. Katman 800 *epoch* civarı) ancak bu uygulandığında başarı oranındaki düşüş yüksek olduğundan biraz daha hata payı bırakarak bu işlemleri uyguladım. Diğer metodlarda da uyguladığım *early stopping* yöntemi aynı değerin gelişinden 25 *epoch* sonra oluşuyor. *Loss* grafikleri yine bize eğitimin tamamlandığını gösteriyor burada gördüğümüz grafikler ilk yöntemden çok az daha iyi gözüküyor ancak yine de yüksek miktarda bir iyileşme getireceğini tahmin etmiyoruz. Ardından karar sınırlarını çıkardığımızda bu tahminimizin doğru olduğunu ve şekil 14, 15 ve 16'da görüleceği üzere SGD'ye çok benzer karar sınırlarının ortaya çıktığını görüyoruz. Ayrıca yine SGD'de yaşadığımız 3 katmanlı mimaride karar sınırı çizilememesi problemi burada da ortaya çıkıyor. Bunun nedenini yine 3 katmanlı ANN yapısının 2 sınıflı 400 verili bir veri seti için çok karmaşık bir yapıya evrildiğini ve karar veremediğini tahmin ediyoruz. Katman sayısı bu seviyede karmaşıklık içeren veri setleri için çok arttırılmamalı. Tüm MBGD mini batch değerleri 32 olarak belirlenmiştir. Ayrıca yine öğrenme katsayısı diğer örneklerde olduğu gibi 0.01 olarak belirlenmiştir.



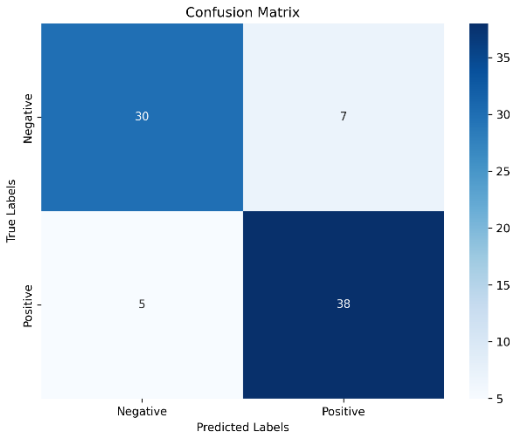
Şekil 14. MBGD 1 Katman Karar Sınırı



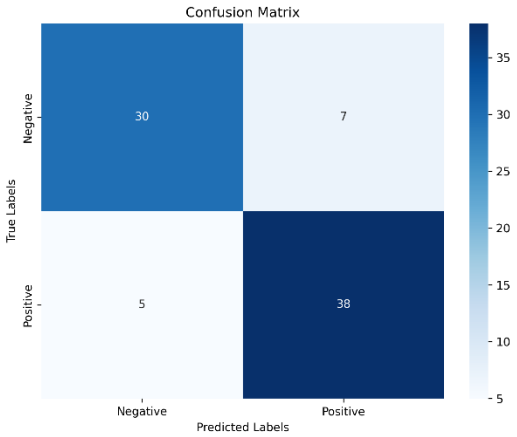
Şekil 15. MBGD 2 Katman Karar Sınırı



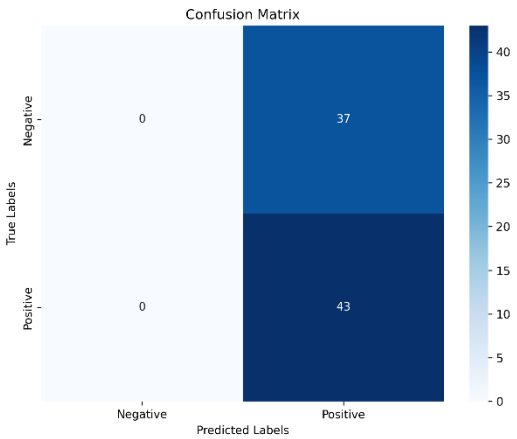
Şekil 16. MBGD 3 Katman Karar Sınırı



Şekil 17. MBGD 1 Katman Confusion Matrix



Şekil 18. MBGD 2 Katman Confusion Matrix



Şekil 19. MBGD 3 Katman Confusion Matrix

Modelin SGD ve birbirleri arasındaki farkları anlamak için şekil 17, 18 ve 19'daki figürlere baktığımızda *confusion matrix*'lerinin dahi ilk yöntemle çok benzer sonuçlar verdiğini görüyoruz.

Confusion matrix'leri ilk örnekle detaylı kıyaslar ve incelersek buradaki elde ettiğimiz tek farkın 1 katmanlı mimarideki 1 değer için olduğunu görebiliriz. Bunun nedeni de muhtemelen yine *lineer* bir sınır çizmeye çalışmamızdan kaynaklanıyor. Bu değerlerin etkilerini daha iyi anlayabilmek adına tüm metrikleri tablo 4, 5 ve 6'da inceleyelim.

TABLO IV. 1 KATMANLI MBGD METRIKLERI

1 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.2862
Doğrulama Kaybı	0.3282
Accuracy	0.85
Precision (Class 0)	0.86
Precision (Class 1)	0.84
Recall (Class 0)	0.81
Recall (Class 1)	0.88
F1-Score (Class 0)	0.83
F1-Score (Class 1)	0.86

TABLO V. 2 KATMANLI MBGD METRIKLERI

2 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.2897
Doğrulama Kaybı	0.3354
Accuracy	0.85
Precision (Class 0)	0.86
Precision (Class 1)	0.84
Recall (Class 0)	0.81
Recall (Class 1)	0.88
F1-Score (Class 0)	0.83
F1-Score (Class 1)	0.86

TABLO VI. 3 KATMANLI MBGD METRIKLERI

3 Katmanlı Vektör Destek Makinesi Sonuçları	
Metrik	***Değer***
Eğitim Kaybı	0.6887
Doğrulama Kaybı	0.6884
Accuracy	0.54
Precision (Class 0)	0.0
Precision (Class 1)	0.54
Recall (Class 0)	0.0
Recall (Class 1)	1.0
F1-Score (Class 0)	0.0
F1-Score (Class 1)	0.7

Tablo 4, 5 ve 6'yı incelediğimizde buradaki skorların yaklaşık değerler kaldığını ancak eğitim kaybı ve doğrulama kaybında SGD yöntemine göre gelişme olduğunu görüyoruz. Yine bir önceki yönteme benzer olarak 1 katmanlı ve 2 katmanlı mimari çok yakın değerler elde etti ancak 1 katamanlı mimari eğitim kaybının bir miktar daha az olduğunu göz önünde bulundurarak bu model için en başarılı modelin 1 katmanlı MBGD olduğunu söyleyebiliriz.

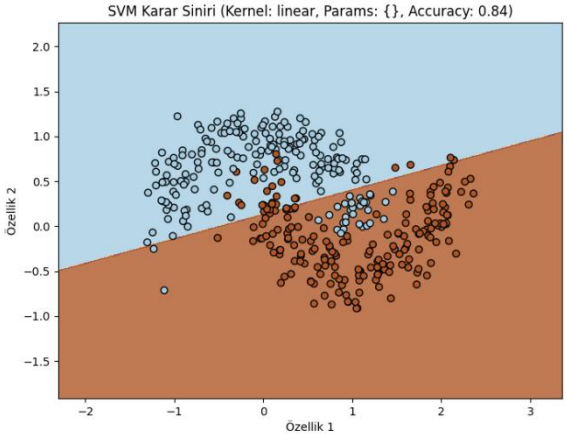
Hem SGD hem de MBGD değerlerine baktığımızda ikisinin de en başarılı modelleri birbirine çok yakın sonuçlar elde etmiş oldu bu durumda diğer metrikleri arasında da en iyi olanı seçtiğimizde 2 katmanlı SGD çok minimal bir farkla daha başarılı oluyor. Ancak 1 veya 2 katmanlı MBGD'de aynı sonuçları vermektedir.

C. Destek Vektör Makineleri (SVM) Öğrenme Modelinin Uygulanması

Daha önce yapmış olduğumuz işlemlere alternatif olarak bir de SVM ile verileri işleyeceğiz. SVM çok daha esnek olduğundan sonuçların daha başarılı olacağını tahmin ediyorum. Ancak burada *overfitting* olma ihtimali yüksek. Öncelikle verilen *kernel*'leri incelediğimizde 3 tip *kernel* kullanılması istenmiş. Herhangi bir standard değer bulunmadığından kerneller için farklı değerleri deneyerek sonuçları karşılaştıracağız.

1) Lineer Kernel

Lineer kernel'i incelediğimizde burada verilebilecek farklı değerler bulunmadığından tek bir sonuç elde edeceğiz. Şekil 20'de karar sınırını gördüğümüz bu *kernel* ANN adımlarında yaptığımız *kernel*'e çok benzer sonuçlar üretmektedir.



Şekil 20. SVM Lineer Kernel Karar Sınırı

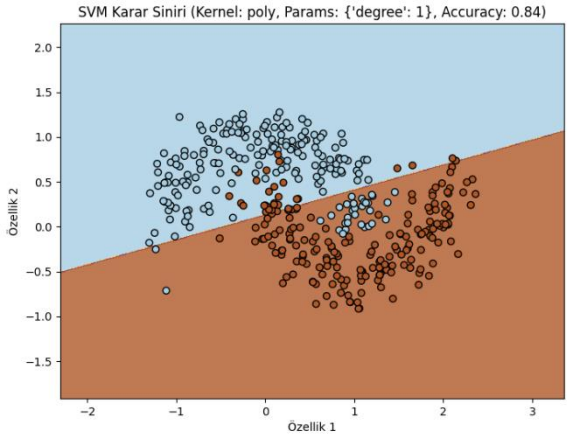
Şekil 20'de yine daha önce karşılaştığımız yapıya benzer bir yapıyla karşılaşıyor ve lineer bir sınır için başarılı bir sonuç alıyoruz. Tüm sonuçları en sonda karşılaştıracağız ancak kesinlik olarak 0. 8375 değerini elde ediyoruz. Bu yine ANN verilerine çok benzer bir değer.

2) Polynomial Kernel

Polynomial kernel sonucumuz şimdiye kadar aldığımız tüm değerlerden daha iyi sonuç vermeli çünkü *lineer* olmayan verilerde daha iyi sonuç verebilmekte. Bundan dolayı çıkacak karar sınırlarının ve doğruluk sonuçlarının çok daha iyi olmasını bekliyoruz. Ancak burada *overfitting* olmaması için dikkatli olmalıyız. Polynomial kernel için 6 adet derece kullanıldı (1'den 6'ya kadar). Bu şekilde en iyi değerleri ölçmek istiyoruz. Polynomial bir değer olduğundan dolayı tek sayılı derecelerde 1 çift sayılı derecelerde 2 karar sınırı bekliyoruz. Bundan dolayı bu veri seti için muhtemel olarak tek sayılı bir derecede en iyi değeri alacağız.

a) Derece: 1

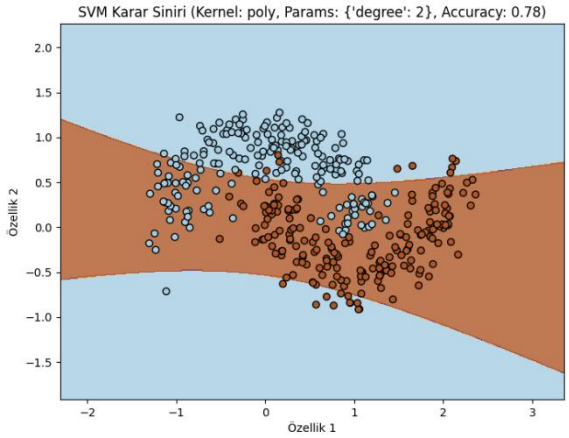
Derece değerini 1 verdiğimizde sonuçlar şekil 21'de görülebileceği karar sınırı ile diğer değerlere yakın olarak çıkıyor. Bunun nedeni derecesi 1 olan polynomial kernelin lineer bir sınır çekmesinden kaynaklanıyor. Bu derecede kesinlik değerini lineer ile aynı olacak şekilde 0.8375 olarak bulduk. Karar sınırı şekil 21'de görülebilir.



Şekil 21. SVM Polynomial Kernel Derece 1 Karar Sınırı

b) Derece: 2

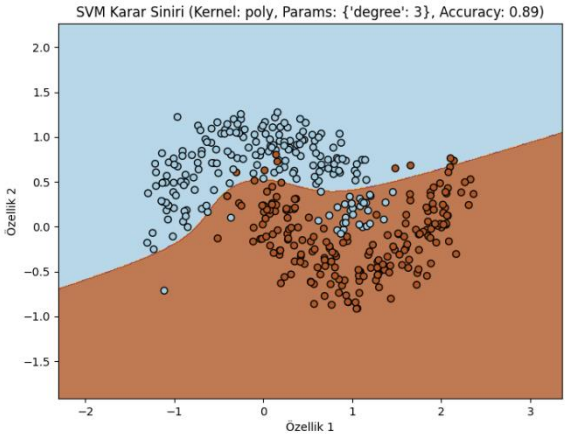
Derece değerini 2 yaptığımızda küp açılımından dolayı çift yönlü bir karar sınırı görüyoruz ve bu sonuç bizim veri setimize de çok uymadığından kesinlik değeri 0.775 olarak düşmüş oluyor. Karar sınırı şekil 22'de görülebilir.



Şekil 22. SVM Polynomial Kernel Derece 2 Karar Sınırı

c) Derece: 3

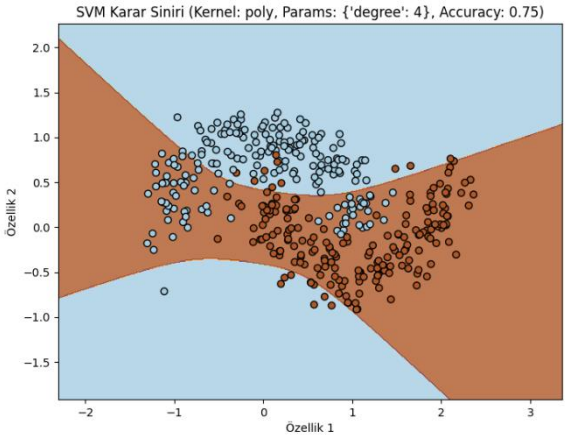
Kayda değer ilk artışı derecenin 3 olarak belirlendiği bu yöntemde görüyoruz. Daha özelleşmiş ve yüksek kesinlik değeri olarak 0.8875 değerini elde ediyoruz. Karar sınırı şekil 23'te görülebilir.



Şekil 23. SVM Polynomial Kernel Derece 3 Karar Sınırı

d) Derece: 4

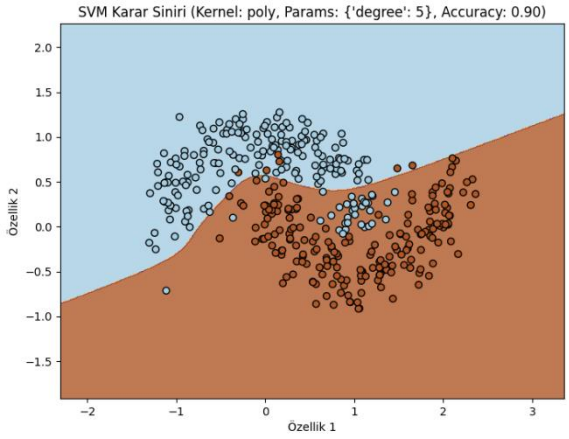
Derece değerini 4 yaptığımızda yine küp açılımından dolayı çift yönlü bir karar sınırı görüyoruz ve bu sonuç bizim veri setimize de çok uymadığından kesinlik değeri 0.75 olarak düşmüş oluyor. Karar sınırı şekil 24'de görülebilir.



Şekil 24. SVM Polynomial Kernel Derece 4 Karar Sınırı

e) Derece: 5

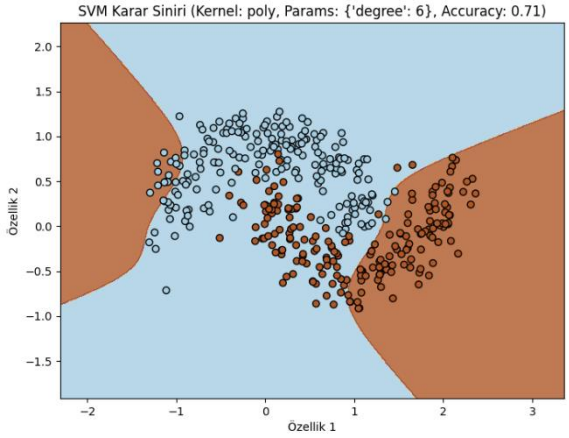
Kesinlik değeri %90 seviyesine çıktığımız ilk model derece değeri 5 olan bu modelden ortaya çıkıyor. 90 değerini geçtiğimizden ötürü buradan sonra arttıracağımız değerler *overfitting*'e neden olmamak adına çok arttırılmadan ve tedbirli kullanılmalıdır. Kesinlik olarak 0.9 elde ediyoruz ve karar sınırımız çok daha anlaşılabilir olmaya başladığını şekil 25'ten görebilirsiniz.



Şekil 25. SVM Polynomial Kernel Derece 5 Karar Sınırı

f) Derece: 6

Derece değerini 6 yaptığımızda bir önceki çift sayılı derecelere benzer olarak küp açılımından dolayı çift yönlü bir karar sınırı görüyoruz ve bu sonuç bizim veri setimize de çok uymadığından kesinlik değeri 0.71 olarak düşmüş oluyor. Karar sınırı şekil 26'de görülebilir.



Şekil 26. SVM Polynomial Kernel Derece 6 Karar Sınırı

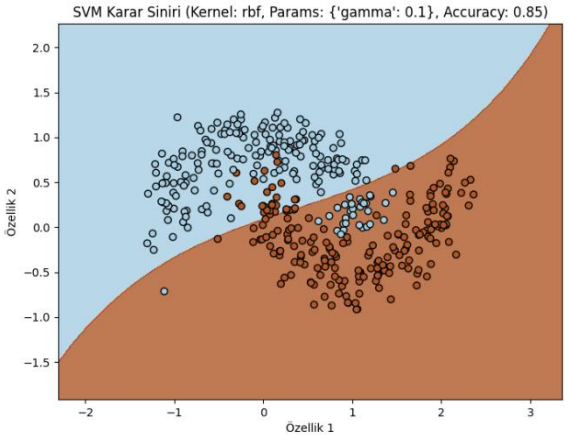
Tüm dereceler gözden geçirildiğinde şekil 25'te bulunan derece 5 değerine sahip polynomial kernel en iyi değeri vermiş gözüküyor. Burada *overfitting*'e sebep olmamak amacıyla yüksek değerlerde arttırılmadan derece denemelerini sonlandırıyorum. Ancak tek sayılı dereceler olmak şartıyla derece değerleri dikkatli bir biçimde arttırılıp daha iyi sonuçlar da elde edilebilir gözüküyor.

3) Gaussian RBF

Gaussian RBF kernel sonucumuz *polynomial kernel*'e benzer olarak ANN sonuçlarından tüm değerlerden daha iyi sonuç vermeli çünkü *lineer* olmayan verilerde daha iyi sonuç verebilmekte. Bundan dolayı çıkacak karar sınırlarının ve doğruluk sonuçlarının çok daha iyi olmasını bekliyoruz. Ancak burada *overfitting* olmaması için dikkatli olmalıyız. Polynomial kernel için 5 adet derece kullanıldı (1'den 5'e kadar). Bu şekilde en iyi değerleri ölçmek istiyoruz. Gaussian bir değer olduğundan dolayı küçük γ değerleri bize daha geniş etki alanı ve daha düz karar sınırları verirken büyük γ değerleri daha dar etki alanı ve daha karmaşık karar sınırları elde etmemize neden olacaktır.

a) γ Değeri: 0.1

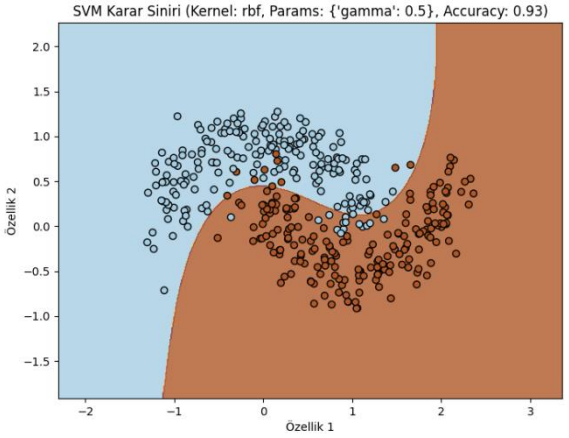
Öncelikle çok küçük bir değerle başlayıp modelin karar sınırlarının nasıl tepki vereceğini ölçtük. Burada almış olduğumuz sonuç *polynomial kernel* üzerinde almış olduğunuz en iyi sonuca benzer bir sonuç elde etmiş olup şekil 27'de görülebileceği gibi kesinlik 0.85 değerini elde etmiş olduk.



Şekil 27. SVM Gaussian RGB Kernel Gamma 0.1 Karar Sınırı

b) γ Değeri: 0.5

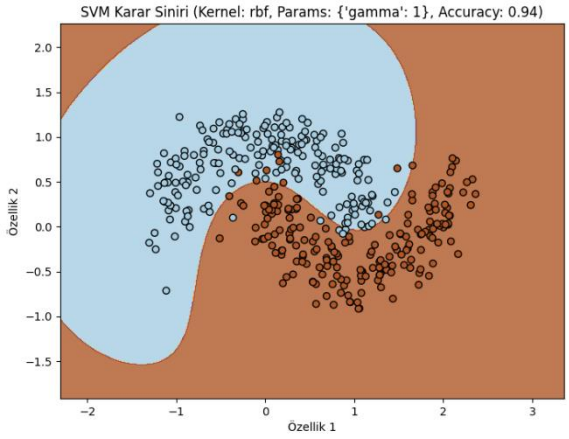
Değeri biraz daha arttırıp karar sınırının verilere göre şekillenmesini takip ettiğimizde şekil 28'de görülebilen daha özelleşmiş bir karar sınırı elde ettik. Bu aşamadan sonraki karar sınırları *overfitting*'e doğru değişecektir. Bundan dolayı *overfitting riskinin en az olduğu en yüksek başarılı karar sınırı* olarak bu değeri belirleyebiliriz. Kesinlik değeri olarak 0.9375 değerini elde etmiş olduk.



Şekil 28. SVM Gaussian RGB Kernel Gamma 0.5 Karar Sınırı

c) γ Değeri: 1

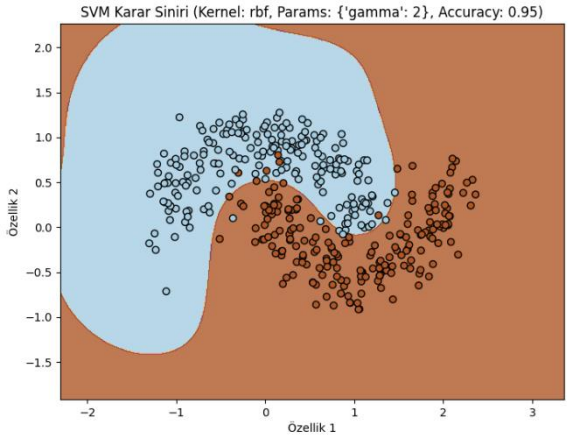
Overfitting riskini alarak skor değerlerini daha çok arttırmak adına daha yüksek değerlerden ilk olarak 1 değerini denediğimizde şekil 29'da görülebileceği üzere kesinlik değeri 0.95 olarak yükseldi ancak karar sınırları *overfitting* belirtileri göstermeye başladı.



Şekil 29. SVM Gaussian RGB Kernel Gamma 1 Karar Sınırı

d) γ Değeri: 2

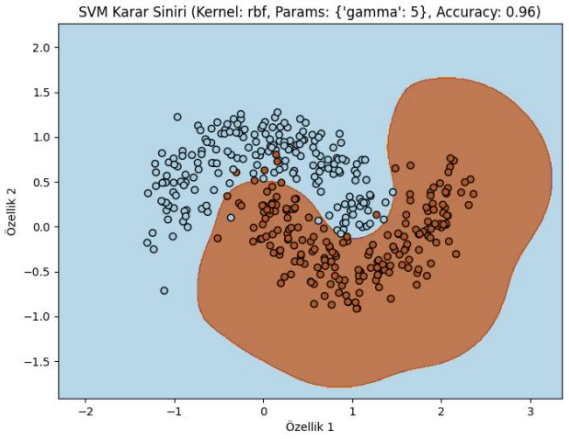
Yine overfitting riskini alarak skor değerlerini daha çok arttırmak adına daha yüksek değerlerden 2 değerini denediğimizde şekil 30'da görülebileceği üzere kesinlik değeri 0.95 olarak yükseldi ancak karar sınırları *overfitting* gösteriyor.



Şekil 30. SVM Gaussian RGB Kernel Gamma 2 Karar Sınırı

e) γ Değeri: 5

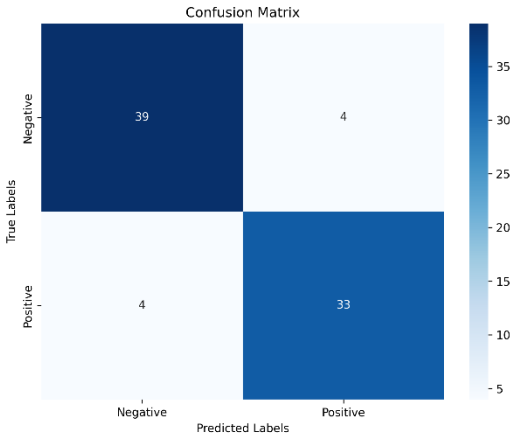
Overfitting artmaya başladığından dolayı dendediğimiz son yüksek değerler olarak 5 değerini denediğimizde şekil 31'de görülebileceği üzere kesinlik değeri 0.9625 olarak yükseldi ancak karar sınırları *overfitting* gösteriyor.



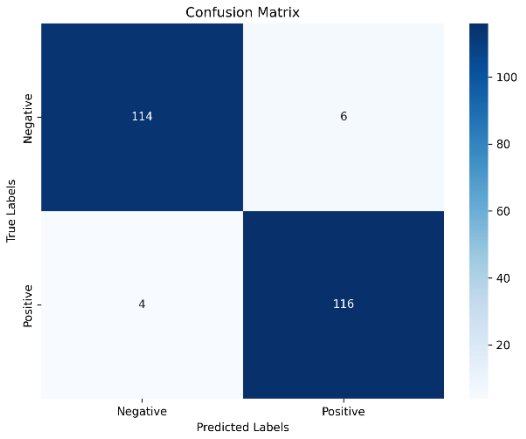
Şekil 31. SVM Gaussian RGB Kernel Gamma 5 Karar Sınırı

Her iki kerneldeki sonuçlarımızı değerlendirdiğimizde en iyi sonucu şekil 31'de bulunan karar sınırında alsak da *overfitting* ihtimalinin en az olduğu en iyi sonucu ise şekil 28'deki karar sınırında almış olduk. Bu iki model için de *confusion matrix* ve metrik değerleri hesaplayalım.

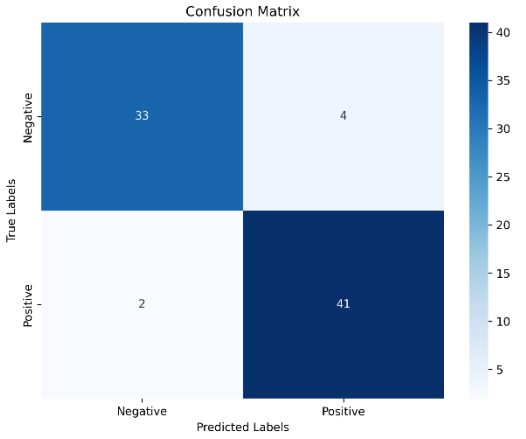
Şekil 28'de karar sınırı görülen ve *overfitting* ihtimali daha az olarak en iyi değeri elde edilmiş olan SVM modeli için test üzerindeki *confusion matrix* şekil 32'de görülebilir. Eğitim üzerindeki *confusion matrix* şekil 33'de görülebilir. Doğrulama üzerindeki *confusion matrix* şekil 34'de görülebilir Ayrıca yükselmiş olan başarı metrik değerleri de tablo 7'de görülebilir.



Şekil 32. SVM Gaussian RGB Kernel Gamma 0.5 Overfitting İhtimali En Az Olan En İyi Sonuç Test Confusion Matrix



Şekil 33. SVM Gaussian RGB Kernel Gamma 0.5 Overfitting İhtimali En Az Olan En İyi Sonuç Eğitim Confusion Matrix

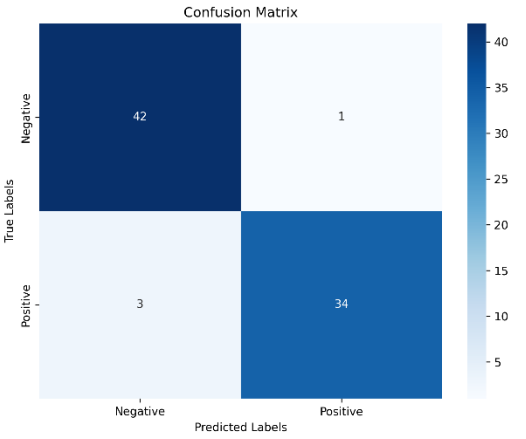


Şekil 34. SVM Gaussian RGB Kernel Gamma 0.5 Overfitting İhtimali En Az Olan En İyi Sonuç Doğrulama Confusion Matrix

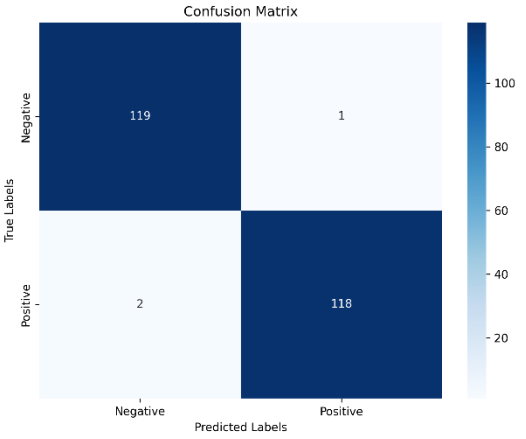
TABLO VII. SVM GAUSSİAN RGB KERNEL GAMMA 0.5 OVERFİTTİNG İHTİMALİ EN AZ OLAN EN İYİ SONUÇ METRİKLERİ

SVM GAUSSİAN RGB KERNEL GAMMA 0.5 OVERFİTTİNG İHTİMALİ EN AZ OLAN EN İYİ SONUÇ METRİKLERİ	
Metrik	***Değer***
Accuracy	0.91
Precision (Class 0)	0.89
Precision (Class 1)	0.91
Recall (Class 0)	0.89
Recall (Class 1)	0.91
F1-Score (Class 0)	0.89
F1-Score (Class 1)	0.9

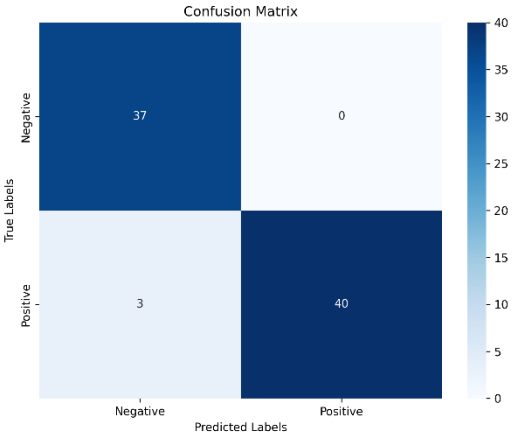
Şekil 31'de karar sınırı görülen ve en iyi değeri elde edilmiş olan SVM modeli için test üzerindeki *confusion matrix* şekil 35'de görülebilir. Eğitim üzerindeki *confusion matrix* şekil 36'de görülebilir. Doğrulama üzerindeki *confusion matrix* şekil 37'de görülebilir Ayrıca yükselmiş olan başarı metrik değerleri de tablo 8'de görülebilir.



Şekil 35. SVM Gaussian RGB Kernel Gamma 5 En İyi Sonuç Test Confusion Matrix



Şekil 36. SVM Gaussian RGB Kernel Gamma 5 En İyi Sonuç Train Confusion Matrix



Şekil 37. SVM Gaussian RGB Kernel Gamma 5 En İyi Sonuç Doğrulama Confusion Matrix

TABLO VIII. SVM GAUSSİAN RGB KERNEL GAMMA 5 EN İYİ SONUÇ METRİKLERİ

SVM GAUSSİAN RGB KERNEL GAMMA 5 EN İYİ SONUÇ METRİKLERİ	
Metrik	***Değer***
Accuracy	0.95
Precision (Class 0)	0.93
Precision (Class 1)	0.97
Recall (Class 0)	0.98
Recall (Class 1)	0.92
F1-Score (Class 0)	0.95
F1-Score (Class 1)	0.94

Bu sonuçlara göre tüm modeller arasında en iyi sonucu aldığımız modelimiz **SVM Gaussian RGB Kernel Gamma Değeri: 5** olmuş oldu.

III. SONUÇ

Bu çalışma, yapay sinir ağları (ANN) ve destek vektör makineleri (SVM) yöntemlerini, doğrusal olmayan bir veri kümesinde karşılaştırarak performanslarını değerlendirmiştir. Yapılan analizlerde, ANN modelleri arasında Mini-Batch Gradient Descent (MBGD) yöntemi ve 1 veya 2 katmanlı yapılar en iyi sonuçları sağlamıştır. Bununla birlikte, katman sayısının artışıyla birlikte aşırı öğrenme (overfitting) probleminin meydana geldiği gözlemlenmiş ve early stopping yöntemi bu sorunu minimize etmekte etkili olmuştur. SVM yönteminde ise Gaussian RBF kernel, gamma = 5 değeri ile doğruluk oranı %95'e ulaşmış ve tüm modeller arasında en yüksek başarıyı göstermiştir. Ancak, gamma değerinin büyümesiyle aşırı öğrenme belirtileri ortaya çıkmıştır. Daha düşük gamma değerlerinde genelleme kabiliyeti daha iyi olsa da doğruluk oranlarında bir miktar düşüş yaşanmıştır. Bu sonuçlar, ANN ve SVM yöntemlerinin performanslarının veri kümesinin özelliklerine ve probleme bağlı olduğunu göstermektedir. Özellikle doğrusal olmayan veri setleri için Gaussian RBF kernel tercih edilse de, farklı veri seti yapıları için ANN yöntemlerinin uygun olabileceği değerlendirilmektedir. Yaptığımız çalışmanın sonuçları model seçimi sırasında veri setinin yapısına ve istenilen sonuçlara göre ölçümler yapılarak modelin seçilmesi gerektiğini göstermektedir.